

第一讲

1.







2.

```
Python 3.13.2 (tags/v3.13.2:4f8bb39, Feb  4 2025, 15:23:48) [MSC v.1942 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license()" for more information.
>>> print("Hello World. Hello 申婷婷")
Hello World. Hello 申婷婷
>>>
```

第一讲

3.



数据与方法

从语料收集到算法句提取的完整pipeline

数据处理Pipeline

01

语料收集

1,767 篇CNL期刊论文全文
时间范围：1993-2016年，覆盖24年演变

02

章节标注

标注7类核心章节

Introduction

Method

Evaluation

Related Work

03

词典构建

构建算法别名词典
覆盖10大经典数据挖掘算法及其变体名称

04

正则抽取

抽取2,328 句“算法句”
精确匹配算法名称 + 上下文语义分析

四维评估指标

频次维度

统计包含某算法的论文数量和平均每篇提及次数，反映算法的普及程度和使用密度

位置维度

不同章节赋予不同权重：Method (0.4) > Evaluation (0.3) > Related Work (0.2) > Others (0.1)

年代维度

分析算法使用的时间演变趋势，识别起步时间、发展速度和当前活跃度

动机维度

区分背景提及与实际调用，细分为4个子类：使用并比较、单一使用、改进并比较、背景引用

10大经典数据挖掘算法

SVM

Naïve Bayes

kNN

决策树

CART

Apriori

EM

k-means

Adaboost

PageRank

首次将“使用动机”纳入算法影响力评估体系



创新点一

引入“使用动机”维度

传统评估只看频次（被提及多少次），本研究首次将使用动机纳入评估体系，区分算法的实际调用与背景介绍。

- ✓ method章节的“使用并比较”权重最高
- ✓ introduction的“背景引用”权重较低
- ✓ 有效过滤“虚假提及”和“致敬式引用”



创新点二

构建四维评估框架

综合频次、位置、年代、动机四个维度，构建更全面的算法影响力评估框架，弥补纯频次评价的片面性。

频次

普及程度

年代

时间趋势

位置

使用深度

动机

使用方式



核心启示

→ 选算法的新标准

应优先关注“谁在method里真实使用”，而非“谁被投票评为经典”。method章节的实际调用比introduction的提及更有说服力

→ Baseline选择策略

选择“使用并比较”模式占比高的算法（如SVM、NB、kNN）作为baseline，能确保对比的公平性和说服力



初学者指导

为算法选择提供客观参考



研究设计

优化baseline选择策略




趋势分析

追踪算法使用演变

第二讲

1.



(1) 信息资源管理

2014-2016: 数字图书馆、知识管理、信息服务模式

2017-2019: 大数据治理、政府数据开放、数据素养

2020-2022: 新文科建设、智慧图书馆、数字人文

2023-2024: 新质生产力、数据要素x、AGI 数智治理

聚类 Q 值 0.71, Silhouette=0.86, 表明学科议题持续集中且更替有序。

(2) 网络营销

2014-2016: 内容营销、O2O、移动社交电商

2017-2019: 短视频营销、KOL/网红经济、私域流量





2020-2022: 直播带货、电商下沉、品牌共创

2023-2024: AIGC 营销、跨境直播、全链路数智化

聚类 Q 值 0.68, Silhouette=0.79, 议题更新快但生命周期短, 与电商实践高度耦合。

第二讲

2.



第二讲

3.

Anaconda Toolbox

v4.20.0

Anaconda

Your Toolbox for Python Projects

Anaconda Cloud

Create a New Project

Create a New Notebook

My Projects

Code Snippets

Manage Code Snippets

Anaconda AI Assistant

Chat-based Python Help

jupyter

tf1_full_text_huangxuhua

Last Checkpoint: 40 minutes ago

File Edit View Run Kernel Settings Help

JupyterLab Python [conda env:base] * Anaconda Toolbox

人们': 1}

[16]: articlelist = sorted(articleDict.items(),key = lambda x:x[1], reverse = True) # 对词典中的词排序

[17]: # 输出词频的前N个
for i in range(100):
 print(articlelist[i])

('黄旭华', 53)
('核潜艇', 32)
('采集', 29)
('学术', 22)
('资料', 21)
('工作', 17)
('成长', 15)
('小组', 14)
('院士', 13)
('进行', 13)
('专业', 13)
('技术', 12)
('研制', 12)
('我国', 12)
('工程', 11)
('访谈', 10)
('第一代', 8)
('介绍', 8)
('主要', 8)
('科学', 8)
('思想', 7)
('人生', 7)
('及其', 7)
('历史', 7)
('传记', 7)
('过程', 6)
('按照', 6)
('要求', 6)
('一生', 6)
('成就', 6)
('研究', 6)
('传主', 6)
('设计', 6)
('实物', 5)
('重点', 5)
('精神', 5)
('先后', 5)
('求学', 5)
('黄旭', 5)
('实现', 5)
('照片', 5)
('重要', 4)
('中国', 4)
('反映', 4)
('成就', 4)

Anaconda Toolbox

v4.20.0

Anaconda

Your Toolbox for Python Projects

Anaconda Cloud

Create a New Project

Create a New Notebook

My Projects

Code Snippets

Manage Code Snippets

Anaconda AI Assistant

Chat-based Python Help

jupyter

tf2_the_huangxuhua

Last Checkpoint: 41 minutes ago

File Edit View Run Kernel Settings Help

JupyterLab Python [conda env:base] * Anaconda Toolbox

[10]: # data_txt词频统计文字中每个词的出现

你没有发现下面的代码很神奇吗？data_txt点count一下，就可以统计词！实际上是字符串匹配的过程！

[11]: for term in terms:
 terms_dict[term]=data_txt.count(term)

[12]: terms_dict

{ '黄旭华': 59, '核潜艇': 32, '国立交通大学': 3}

[23]: # 定义 画图 函数

[13]: def make_chinese_plot_ready():
 from matplotlib import rcParams
 rcParams['font.family'] = 'Heiti TC' # mac笔记本电脑直接替换字体
 #rcParams['font.sans-serif'] = ['FangSong'] # 或者直接使用电脑有的字体 FangSong
 rcParams['axes.unicode_minus'] = False

[14]: # 定义 画图 函数

[15]: def draw_dict(mydict, figsize=(8, 5)):
 import pandas as pd
 import matplotlib.pyplot as plt
 make_chinese_plot_ready()
 df = pd.DataFrame(list(mydict.items()), columns=['name', 'times'])
 df.set_index('name')['times'].sort_values(ascending=False).plot(kind='bar', figsize=figsize) # 做好排序
 plt.tight_layout()

[16]: # %pylab inline

[17]: %matplotlib inline

[18]: draw_dict(terms_dict)

科学声誉的“长寿”：牛顿 vs. 爱因斯坦

The Longevity of Scientific Reputation: Newton vs. Einstein

研究背景与数据规模

- 数据源：Google Books 3,600万本书籍 + Google Scholar 9,100万篇学术文章
- 指标设计：全名在书籍/文献中的出现频次 = 公众声誉
- 时间跨度：1700-2008年，覆盖两位科学家逝世后的 centuries

核心发现

- 全球趋势：自1980年代起，爱因斯坦超越牛顿
- 地域差异：英国书籍中，牛顿始终领先 → “本族偏好”效应
- 共现分析：

爱因斯坦

相对论 28% + 量子 17%


牛顿

万有引力 15% + 微积分 8%

研究结论

科学家的肉身易逝，但其名字与核心贡献可在人类记忆中“存活”数百年，超越时空局限。

科学声誉变迁趋势（1700-2008）



数据来源：Google Books Ngram Viewer | 访问时间：2016年1月

第三讲

1.



词云图以“城市”、“咖啡”、“公园”、“面包”、“公司”、“人们”等高频名词为核心，形成中心密集、四周发散的布局。




暖色调（橙、黄、粉）集中在“阳光、咖啡、面包、温暖、微笑、希望”等词上，传递出温柔、日常、治愈的情绪。

冷色调（蓝、青、灰）则出现在“夜幕降临、霓虹灯、鸣笛、思考、回忆”等词上，带出城市夜色中的孤独与沉思。

绿色系可能用于“公园、树叶、微风、慢跑”，强化自然与放松的意象。



第三讲

2.





第三讲

3.



第三讲

4.



第四讲

1.

在线演示

HanLP

安装

演示

文档

书籍

引用

论坛

博客

API

🇨🇳

🌐

🔍

搜索

HanLP

情感分析

请输入一段中文文本：

“这是一部男人必看的电影。”人人都这么说。但单纯从性别区分，就会让这电影变狭隘，《肖申克的救赎》突破了男人电影的局限，通篇几乎充满令人难以置信的温馨基调，而电影里最伟大的主题是“希望”。当我们无奈地遇到了如同肖申克一般囚禁了心灵自由的那种囚徒，我们是无奈的老布鲁克，灰心的瑞德，还是智慧的安迪？运用智慧，信任希望，并且勇敢面对恐惧心理，去打败它？ 经典的电影之所以经典，因为他们都在做同一件事——让你从不同的角度来欣赏希望的美好。

215/1000

情感分析

简介

情感分析（Sentiment Analysis）任务的目标是判断一段文本的情感极性。情感极性为 [-1, 1] 之间的数值，数值的正负代表正负面情绪，数值的绝对值代表情感的强烈程度。

调用方法

创建客户端

```
from hanlp_restful import HanLPClient
# 支持zh中文, en英语, ja日语, mu1多语种
HanLP = HanLPClient('https://www.hanlp.com/api', auth=None, language='zh')
```

运行

可编辑 & 一键云端运行

READY

申请密钥

由于服务器算力有限，匿名用户每分钟限2次调用。如果你需要更多调用次数，[建议申请免费公益API密钥auth](#)。

情感分析

在线演示

HanLP

安装

演示

文档

书籍

引用

论坛

博客

API

🇨🇳

🌐

🔍

搜索

HanLP

情感分析（Sentiment Analysis）任务的目标是判断一段文本的情感极性。情感极性为 [-1, 1] 之间的数值，数值的正负代表正负面情绪，数值的绝对值代表情感的强烈程度。

调用方法

创建客户端

```
from hanlp_restful import HanLPClient
# 支持zh中文, en英语, ja日语, mu1多语种
HanLP = HanLPClient('https://www.hanlp.com/api', auth=None, language='zh')
```

运行

可编辑 & 一键云端运行

READY

申请密钥

由于服务器算力有限，匿名用户每分钟限2次调用。如果你需要更多调用次数，[建议申请免费公益API密钥auth](#)。

情感分析

执行情感分析：

```
text = '''这是一部男人必看的电影。”人人都这么说。但单纯从性别区分，就会让这电影变狭隘。《肖申克的救赎》突破了男人电影的局限，通篇几乎充满令人难以置信的温馨基调，而电影里最伟大的主题是“希望”。当我们无奈地遇到了如同肖申克一般囚禁了心灵自由的那种囚徒，我们是无奈的老布鲁克，灰心的瑞德，还是智慧的安迪？运用智慧，信任希望，并且勇敢面对恐惧心理，去打败它？经典的电影之所以经典，因为他们都在做同一件事——让你从不同的角度来欣赏希望的美好。'''
HanLP.sentiment_analysis(text)
```

运行

可编辑 & 一键云端运行

READY

0.9505730271339417



返回值为文档的情感极性，表示为 [-1, +1] 之间的数值。

本地调用




第四讲

2.




第四讲

2.



这段脚本准备把“评论文本”→“情感分数”→“时间序列”→“可视化趋势线”，用来快速监控一家餐厅在 2017 年 4-5 月的口碑起伏；下一步就是跑循环打分 + resample 画图即可。



极性倾向：极度正向

关键词如“无名英雄”“隐姓埋名”“无私奉献”“艰苦奋斗”“感召一代又一代”等，情感浓度极高，无负面词汇。

情感强度：强烈

使用大量褒义形容词+集体主义叙事，如“完美诠释”“肩负历史重任”“献身国防”，情绪被推向崇高感。

阿里数字商业 知识图谱 2025

极性倾向：极度正向

关键词如“无名英雄”“隐姓埋名”“无私奉献”“艰苦奋斗”“感召一代又一代”等，情感浓度极高，无负面词汇。

情感强度：强烈

让 30+ 业务"一张图"做生意

使用大量褒义形容词+集体主义叙事，如“完美诠释”“肩负历史重任”“献身国防”，情绪被推向崇高感。

10亿+ 实体 | 百亿+ 关系 | 1.2亿+ 日均推理

Latest Updates

最新进展

2025年度核心数据与技术突破全景呈现

规模数据

构建全球最大规模的数字商业知识图谱之一，覆盖商品、商家、类目、规则等多维度实体，支撑海量关系的实时推理与查询。

10亿+

实体数量

商品/商家/类目/规则

百亿+

关系规模

多维度语义关联

1.2亿

日均推理

支持实时业务决策

荣誉与成就

2024年度浙江省科技进步二等奖，技术创新与产业应用价值获得权威认可。

天猫

淘宝

饿了么

盒马

银泰

30+ 业务单元

技术突破

超大规模预训练 + 知识注入

将图谱结构直接写进BERT高层，实现知识与语言的深度融合。

↑ 商品分类小样本准确率 +3%

企业级平台架构

半结构-非结构混合存储 + 图数据库，实现高效数据管理与实时更新。

🕒 支持小时级全量更新


迷你案例

商品发布场景：冷启动问题的图谱解决方案



痛点分析

新商品无历史节点，缺乏图谱中的关联特征，无法直接利用图谱进行智能分类与属性预测。



解决方案

基于"同类商品簇"生成虚拟子图，将结构化知识注入KnowBERT，实现在线预测。

1

同类商品簇 → 虚拟子图

基于商品相似性，动态构建包含语义关联的虚拟子图，为新商品提供临时图谱环境。

2

子图向量 → KnowBERT注入

将子图结构编码为向量，直接写入KnowBERT高层，实现知识与语言的深度融合。

3

在线预测 → 智能决策

实时预测类目、属性、风险标记，支持商品发布全流程的智能化与自动化。

89%

冷启动类目预测 Top1 准确率

相比基线 86% 显著提升

40%

平台治理审核人力节省

降本增效成果显著

关键词：

冷启动

虚拟子图

KnowBERT

商品发布

图谱预训练

生态玩法

构建平台、商业、学术三位一体的知识图谱生态体系



平台层

技术基础设施

阿里云知识图谱引擎

提供一站式知识图谱构建与运维服务，降低企业应用门槛。

- ✔ **自动抽取**
从非结构化数据中自动提取知识
- ✔ **本体设计**
可视化构建领域知识模型
- ✔ **低代码运维**
简化图谱部署与维护流程



商业层

行业应用落地

行业SaaS模板输出

将零售领域经验沉淀为可复用的行业模板，向金融、能源等领域输出。

 **电力设备图谱**
设备故障诊断与运维优化

 **银行风控图谱**
信贷风险评估与反欺诈

 **多行业**
可复用模板快速部署



学术层

科研合作与开放

产学研深度合作

与浙江大学共建数字商务联合实验室，推动知识图谱前沿研究。

 **数据集开放计划**
2025年度已开放**3个千万级**大规模数据集
覆盖商品、商家、关系等多维度，支持学术研究

核心价值

- 推动知识图谱技术创新
- 培养专业人才队伍
- 促进学术成果转化



信管视角的3点评价

信息管理与信息系统专业视角下的技术价值与行业意义

1

数据治理标杆

把多源异构数据变成可解释、可推理的"商业语义层"，为后续BI、RAG、Agent提供统一上下文。

- 解决数据孤岛问题
- 提升数据可解释性
- 支持多场景应用

2

小样本友好

图谱预训练缓解"新产品无数据"难题，对信息系统中冷启动场景极具借鉴意义。

+3%

小样本分类准确率提升

40%

审核人力成本节省

3

可复制性

平台化 + 行业模板 降低实施门槛，为学生提供毕业设计和竞赛项目思路。

三步法

本体设计 → 业务规则 → 经济收益

适用场景

毕业设计、竞赛项目、研究课题




核心价值总结

技术领先性 + 场景实用性 + 生态可持续性


为信息管理领域提供
最佳实践范式

第六讲

1.




2.



我和不同朋友对于不同美剧的喜欢关系表达

第六讲

3.



4.

