



南京工业大学
NANJING TECH
UNIVERSITY

用户数据采集与关联分析

(结课作业)





南京工业大学
NANJING TECH
UNIVERSITY


01 文本数据分析



第一讲 课程导言与分词（案例演示截图）



第一讲 课程导言与分词(anaconda代码测试)



第一讲 课程导言与分词（课后作业001）

①

```
1 基本操作

In [1]: pip install jieba

Requirement already satisfied: jieba in d:\an\lib\site-packages (0.42.1)

DEPRECATION: pandas 0.23.4 has a non-standard dependency specifier pyts>=0.10.1k. pip 24.1 will enforce this behaviour change. A possible replacement is to upgrade to a newer version of pandas or contact the author to suggest that they release a version with a conforming dependency specifiers. Discussion can be found at https://github.com/pypa/pip/issues/12065

In [2]: import jieba # 在命令行界面安装分词软件jieba # pip install jieba

In [3]: seg_list = jieba.cut("南京大学生都爱南京市长江大桥")

In [4]: print(' '.join(seg_list))

Building prefix dict from the default dictionary...
Loading model from cache C:\Users\LEGION\AppData\Local\Temp\jieba.cache
Loading model cost 1.157 seconds.
Prefix dict has been built successfully.
南京 大学生 都 爱 南京市 长江大桥

In [5]: seg_list = jieba.cut("南京大学生都爱南京市长江大桥")

In [6]: print(' '.join(seg_list))

南京*大学生*都*爱*南京市*长江大桥

2 加入用户词典

In [7]: seg_list1 = jieba.cut("吴志祥是南京工业大学青年教师，他对那种二次元小魔仙是无感的，这怎么行？")

In [8]: print(' '.join(seg_list1))

吴志祥是南京工业大学青年教师，他对那种二次元小魔仙是*无感的*的，*这怎么才行*？

载入词典

In [9]: jieba.load_userdict('dict.txt')
```

②

③

```
结论：中文分词用jieba

5课后作业

你可以使用以下两个片段，完成1-2的操作（我已经运行过一篇，你需要把块删掉的部分重新加上，获得同样的结果，试一试？）

1. 曾经有一份真诚的爱情摆在我的面前，我没有珍惜，等到失去的时候才追悔莫及，人世间最痛苦的事情莫过于此。如果上天能够给我一个再来一次的机会，我会对那个女孩子说三个字：我爱你。如果要给这份爱情加上一个期限，我希望，是一万年。

2. LSTM (Long Short-Term Memory) 是长短期记忆网络，是一种时间递归神经网络，适合于处理输入输出序列中时间间隔和延迟较长的重要事件。

3. 吴志祥，1929年3月12日出生于广东省汕头市，原名吴日升，1949年毕业于上海交通大学，历任北京海军核潜艇研究所总工程师、中船重工集团公司核潜艇总体设计研究所研究员、名誉所长，1994年当选为中国工程院院士。

1.基本分词

In [26]: import jieba

In [27]: seg_list1 = jieba.cut("曾经有一份真诚的爱情摆在我的面前，就没有珍惜，等到失去的时候才追悔莫及，人世间最痛苦的事情莫过于此。如果上天能够给我一个再来一次的机会，我会对那个女孩子说三个字：我爱你。如果要给这份爱情加上一个期限，我希望，是一万年。")

In [28]: print(' '.join(seg_list1))

曾经有一份真诚的爱情摆在我的面前，我没有珍惜，等到失去的时候才追悔莫及，人世间最痛苦的事情莫过于此。如果上天能够给我一个再来一次的机会，我会对那个女孩子说三个字：我爱你。如果要给这份爱情加上一个期限，我希望，是一万年。

2.加入词典，是针对第二个片段的，希望是能够完整把“长短期记忆网络”这个术语整体分割出来

In [31]: jieba.load_userdict('dict.txt')
```

④

```
3 载入停用词

In [12]: seg_list = jieba.cut("没有使用停用词的的分词结果，就会有很多没有用的词啊，虚词、感叹词什么的")

In [13]: print(' '.join(seg_list1))

没有*使用*停用*词表*的*分词*结果*，*就*会*有*很多*没有*用*的*词*啊*，*虚*词*，*感*叹*词*什*么*的*

载入停用词表

In [14]: stopwords = [line.strip() for line in open('stop_words.txt', 'r', encoding='utf-8').readlines()]

In [15]: seg_list = jieba.cut("使用了停用词表之后啊，效果就好看很多了，什么啊，了、是之类的词就不见了")

In [16]: final = ""

In [17]: for seg in seg_list:
    if seg not in stopwords:
        final += seg + " "

In [18]: print(final) # 在实体抽取的时候，停用词表很实用

使用*词表*之后*效果*就*好看*很多*什么*之类*的词*就*不*见*


4 jieba分词与SnowNLP分词进行比较

In [19]: from snowlp import SnowNLP

In [20]: s = SnowNLP("质量不大好")
```

```
1/3/2026
```

第一讲 课程导言与分词(课后作业002)



```
In [1]: # 简单分词

In [2]: import jieba

In [3]: seg_list_huang = jieba.cut("黄旭华, 1926年3月12日出生于广东省汕尾市, 原籍广东省揭阳市。1949年毕业于上海交通大学。历任北京海军核潜艇研究室")

In [4]: print(' '.join(seg_list_huang))

Building prefix dict from the default dictionary ...
Loading model from cache C:\Users\LEGION\AppData\Local\Temp\jieba.cache
Loading model cost 1.358 seconds.
Prefix dict has been built successfully.

黄旭华, /1926/年/3/月/12/日出/生于/广东省/汕尾市/, /原籍/广东省/揭阳市/, /1949/年/毕业/于/上海交通大学/, /历任/北京/海军/核潜艇/研究
室/副/总工程师/, /中/船/重工/集团公司/核潜艇/总体/研究/设计所/研究员/, /名誉/所长/, /1994/年/当选/为/中国工程院/院士/。

In [5]: # 加入用户词典

In [6]: jieba.load_userdict('dict.txt')

In [7]: seg_list_huang = jieba.cut("黄旭华, 1926年3月12日出生于广东省汕尾市, 原籍广东省揭阳市。1949年毕业于上海交通大学。历任北京海军核潜艇研究室")


In [8]: print(' '.join(seg_list_huang))

黄旭华/, /1926/年/3/月/12/日出/生于/广东省/汕尾市/, /原籍/广东省/揭阳市/, /1949/年/毕业/于/上海交通大学/, /历任/北京/海军/核潜艇/研究
室/副/总工程师/, /中船重工集团公司/核潜艇/总体/研究/设计所/研究员/, /名誉/所长/, /1994/年/当选/为/中国工程院院士/。

In [9]: # 加入词典之后, 哪些词汇被分出来了呢?

In [10]: # 使用停用词表

In [11]: # stopwords = [line.strip() for line in open('stop_words.txt', 'r', encoding='utf-8').readlines()]
```



```
In [9]: # 加入词典之后, 哪些词汇被分出来了呢?

In [10]: # 使用停用词表

In [11]: # stopwords = [line.strip() for line in open('stop_words.txt', 'r', encoding='utf-8').readlines()]

In [12]: stopwords = open('stop_words.txt', 'r', encoding='utf-8').read()
stopwords = stopwords.split('\n')

In [13]: stopwords

Out[13]: ['的', '了', '是', '啊', '、', ' ', ' ', ' ', ' ', ' ', '停用']

In [14]: seg_list_huang = jieba.cut("黄旭华, 1926年3月12日出生于广东省汕尾市, 原籍广东省揭阳市。1949年毕业于上海交通大学。历任北京海军核潜艇研究室")

In [15]: final = ''

In [16]: for seg in seg_list_huang:
    if seg not in stopwords:
        final+= seg+'/'

In [17]: print(final)

黄旭华/1926/年/3/月/12/日出/生于/广东省/汕尾市/原籍/广东省/揭阳市/1949/年/毕业/于/上海交通大学/历任/北京/海军/核潜艇/研究室/副/工程
师/中船重工集团公司/核潜艇/总体/研究/设计所/研究员/名誉/所长/1994/年/当选/为/中国工程院院士/

作业的意义:

• 你可以处理比较复杂的文本啦
• 你开始尝试接触和理解, 一些具有文化内涵的科技文献资源

In [ ]:

In [ ]:
```

第一讲 课程导言与分词(课后作业003)

hz/003-NER-企业年报-数字技术-安全管理 (autosaved)

File Edit View Insert Cell Kernel Widgets Help Trusted Python 3

Run Code

第一步：对文本进行分词，返回分词结果。
我们的步骤是：1) 使用jieba分词，对文本进行分词；2) 统计给定词汇的频率，比如：自动化、数字化、安全。

In [4]:
import jieba
from collections import Counter

In [5]:
文本
text = """
落实“企业管理年”主题，加强QHSE三体系建设，
通过自动化、数字化、智能化升级改造加快新一代信息技术与企业生产经营融合，
打造精益制造能力，提升精细化管理水平，助力公司从“制造”升级为“智造”，
从而提高经营效率和效益；通过集团一体化智慧管理平台建设与运营，
丰富企业供应链管理、生产工艺控制等管理工具，不断增强生产经营过程数据获取与分析能力，
强化全过程一体化管理，提高自动化、数字化、智能化的供应链管理能力和
为体系安全稳定运行与管理水平提升保驾护航，致力打造安全智能化工厂；
打造助力互联网技术合作和商务合作平台，构建具有国际竞争力的供应链体系。
"""

In [6]:
1. 分词处理
words = jieba.lcut(text)

In [7]: words

Out[7]: ['\n',
'落实',
'，',
'企业',
'管理',
'年',
'，',
'主题',
'，',
'加强',
'QHSE',
'三',
'，',
'体系',
'建设',
'，',
'\n',
'通过',
'，',
'自动化',

hz/003-NER-企业年报-数字技术-安全管理 (autosaved)

File Edit View Insert Cell Kernel Widgets Help Trusted Python 3

Run Code

2. 定义要统计的特殊词汇
target_words = ['数字化', '智能化', '安全']

In [9]:
统计词频
word_counts = Counter(words)

In [10]:
输出特定词汇的词频统计结果
print("特定词汇词频统计结果：")
for word in target_words:
 print(f"{word}: {word_counts[word]} 次")

In [11]:
输出所有词汇的词频（按频率降序）
print("\n所有词汇词频统计（前20个）：")
for word, count in word_counts.most_common(20):
 print(f"{word}: {count} 次")

所有词汇词频统计（前20个）：
'，': 13次
'': 9次
'管理': 5次
'，': 5次
'与': 4次
'，': 3次
'企业': 3次
'，': 3次
'体系': 3次
'智能化': 3次
'经营': 3次
'打造': 3次
'能力': 3次
'供应链': 3次
'建设': 2次
'通过': 2次
'自动化': 2次
'数字化': 2次
'升级': 2次
'生产': 2次

第一讲 课程导言与分词(课后作业004)

hz/

004_使用大语言模型提取科技文献中的实体.ipynb

004_使用大语言模型提取科技文献中的实体.ipynb

004_使用大语言模型提取科技文献中的实体 (unsaved changes)

File Edit View Insert Cell Kernel Widgets Help Trusted Python 3

In [2]:

```
import requests
import json

# 定义DeepSeek API的URL和headers
DEEPSEEK_API_URL = "https://api.deepseek.com/v1/chat/completions"
API_KEY = "sk-78e6472776046394135e9246255cfa" # 直接复制过来
```

In [3]:

```
# 准备prompt和论文文本
paper_text = """
随着肿瘤免疫微环境 (Tumor Immune Microenvironment, TIME) 研究的深入，
T细胞耗竭 (T cell exhaustion) 被认为是限制免疫治疗效果的关键机制之一。
本研究基于免疫编辑理论，提出了一种基于单细胞RNA测序 (scRNA-seq) 的T细胞状态动态识别方法。
具体而言，我们使用Seurat与Monocle3等生物信息学工具对50例非小细胞肺癌患者的肿瘤样本进行细胞亚群聚类和轨迹分析，
结合pseudotime推断T细胞从激活到耗竭的转化过程。此外，借助CellChat软件构建细胞间通讯网络，
进一步识别可能诱导T细胞耗竭的免疫抑制信号通路，如PD-1/PD-L1和TIGIT-β 路径。研究结果揭示了T细胞功能衰竭的关键节点，并为个体化免疫治疗提供了新策略。
"""

prompt = f"""
请从以下科技论文文本中提取包含理论、方法、工具的实体或专业术语，以json字典的格式输出：
{paper_text}
"""
```

In [4]:

```
# 准备请求数据
data = {
    "model": "deepseek-chat",
    "messages": [
        {
            "role": "user", "content": prompt
        }
    ],
    "temperature": 0.3
}

headers = {
    "Content-Type": "application/json",
    "Authorization": f"Bearer {API_KEY}"
}

# 发送请求
response = requests.post(DEEPSEEK_API_URL, headers=headers, data=json.dumps(data))
```

In [5]:

```
# 处理响应
if response.status_code == 200:
    result = response.json()
    try:
        entities = result['choices'][0]['message']['content']
        print("提取到的实体和专业术语:")
        print(entities)
    except KeyError:
        print("无法解析API响应，原始响应:")
        print(result)
else:
    print(f"请求失败，状态码: {response.status_code}")
    print(response.text)
```

提取到的实体和专业术语:

...json

{

"理论": [

"肿瘤免疫微环境",

"T细胞耗竭",

"免疫编辑理论"

],

"方法": [

"单细胞RNA测序",

"细胞亚群聚类",

"轨迹分析",

"pseudotime推断",

"细胞间通讯网络构建"

],

"工具": [

"Seurat",

"Monocle3",

"CellChat"

],

"专业术语": [

"TIME",

"scRNA-seq",

"非小细胞肺癌",

"免疫抑制信号通路",

"PD-1/PD-L1",

"TIGIT-β 路径",

"个体化免疫治疗"

]

}...

搜索 复制 翻译 问问AI

004_使用大语言模型提取科技文献中的实体 (unsaved changes)

File Edit View Insert Cell Kernel Widgets Help Trusted Python 3

In [5]:

```
# 处理响应
if response.status_code == 200:
    result = response.json()
    try:
        entities = result['choices'][0]['message']['content']
        print("提取到的实体和专业术语:")
        print(entities)
    except KeyError:
        print("无法解析API响应，原始响应:")
        print(result)
else:
    print(f"请求失败，状态码: {response.status_code}")
    print(response.text)
```

提取到的实体和专业术语:

...json

{

"理论": [

"肿瘤免疫微环境",

"T细胞耗竭",

"免疫编辑理论"

],

"方法": [

"单细胞RNA测序",

"细胞亚群聚类",

"轨迹分析",

"pseudotime推断",

"细胞间通讯网络构建"

],

"工具": [

"Seurat",

"Monocle3",

"CellChat"

],

"专业术语": [

"TIME",

"scRNA-seq",

"非小细胞肺癌",

"免疫抑制信号通路",

"PD-1/PD-L1",

"TIGIT-β 路径",

"个体化免疫治疗"

]

}...

搜索 复制 翻译 问问AI

第一讲 课程导言与分词

基于学术论文全文内容的算法使用行为及其影响力研究总结

研究背景

大数据环境下数据挖掘算法应用广泛，初学者亟需高效选择算法。现有评估方法依赖特定数据集、门槛高，而学术论文含算法使用细节，基于全文分析评估算法影响力更具普适性，故开展相关研究。


研究方法

以 NLP 领域 1993-2016 年 CCL 会议 1767 篇论文为语料，构建十大算法词典抽取算法句，从使用频次、位置、年代、动机四维度，全面分析算法使用行为并评估影响力。

研究结论

SVM 算法在 NLP 领域影响力最高，CART 与 Apriori 算法较低；算法客观评估结果异于专家主观票选，且国内算法使用起步滞后国外但发展同步，可为研究者算法选择提供参考。

第二讲 词频统计(信息资源管理主题变化趋势)



第二讲 词频统计(全文词频统计)

[illegible]

第二讲 词频统计(全文词频统计)

[illegible][illegible][illegible]

第二讲 词频统计(指定类型词频统计)

①


```
In [1]: # 文件的打开与关闭
In [2]: f_name = open('name.txt', encoding = 'GB18030') #使用utf8的小伙伙，需要耐心调试了编码GB18030
In [3]: f_name = open('name.txt')
In [4]: data_name = f_name.read()
In [5]: data_name[:70]
Out[5]: '诸葛亮|关羽|刘备|曹操|孙权|刘备|吕布|周瑜|诸葛亮|司马懿|黄忠|马超'
In [6]: print(data_name[:50])
诸葛亮|关羽|刘备|曹操|孙权|刘备|吕布|周瑜|诸葛亮|司马懿|黄忠|马超
In [7]: f_name.close()
In [8]: # 将文本拆分为列表
In [9]: names = data_name.split('|') # split--下划线就是列表
In [10]: print(names)
['诸葛亮', '关羽', '刘备', '曹操', '孙权', '刘备', '吕布', '周瑜', '诸葛亮', '司马懿', '黄忠', '马超']
In [11]: names
Out[11]: ['诸葛亮',
'关羽',
'刘备',
'曹操',
'孙权',
'刘备',
'吕布',
'周瑜',
'诸葛亮',
'司马懿',
'黄忠',
'马超']
```

②

```
In [12]: # 学习一种新的数据结构：字典
In [13]: name_dict = {}
In [14]: f_txt = open('name.txt', encoding = 'GB18030')
In [15]: data_txt = f_txt.read()
In [16]: f_txt.close()
In [17]: print(data_txt[:100])
<三国演义> (全)
(明) 罗贯中著
第一回
话说桃园三结义...
...
你发现下面的代码很神奇吗？data_txt.count一下，就可以统计词！实际上是字符串匹配的过程！
In [19]: for name in names:
name_dict[name]=data_txt.count(name)
In [20]: name_dict
Out[20]: {'诸葛亮': 140,
'关羽': 8,
'刘备': 291,
'曹操': 907,
'孙权': 115,
'司马懿': 347,
'吕布': 332,
'周瑜': 256,
'马超': 301,
'': 1}
```


③

```
In [22]: def make_chinese_plot_ready():
from matplotlib import rcParams
rcParams['font.family'] = 'MeiTi TC' # 默认记本电脑直接替换字体
# rcParams['font.name-serif'] = ['FangSong'] # 前者直接使用电脑有的字体 FangSong
rcParams['axes.unicode_minus'] = False
In [23]: # 定义 画图 函数
In [24]: def draw_dict(mydict, figsize=(8, 5)):
import pandas as pd
import matplotlib.pyplot as plt
make_chinese_plot_ready()
df = pd.DataFrame(list(mydict.items()), columns=['name', 'times'])
df.set_index('name')['times'].sort_values(ascending=False).plot(kind='bar', figsize=figsize) # 很好排序
plt.tight_layout()
In [25]: # 调用 inline
In [26]: %matplotlib inline
In [27]: draw_dict(name_dict)
D:\matplotlib\site-packages\matplotlib\font_manager.py:1331: UserWarning: findfont: Font family ['MeiTi TC'] not found. Falling back to DejaVu Sans
(prop.get_family(), self.defaultFamily(fontset1))
```



name	times
曹操	907
司马懿	347
马超	301
吕布	332
周瑜	256
诸葛亮	140
刘备	291
关羽	8
孙权	115
刘备	8
马超	1

第二讲 词频统计(指定类型词频统计)



第二讲 词频统计(指定类型词频统计)

①

```
In [2]: #f_name = open('name.txt', encoding = 'GB18030') #能用gbk的小伙伴，请要耐心试试编码GB18030
In [3]: #f_name = open('name.txt')
In [4]: #data_name = f_name.read()
In [5]: #data_name[:10]
In [6]: #print(data_name[:50])
In [7]: #f_name.close()
In [8]: # 将文本转换为列表
In [9]: #name = data_name.split(',') # split——分割数据列表
In [10]: # 以上流程演示重新的方法，将你的数据统计的词汇放置到txt文本中
# 我们重复统计的词汇减少，数据就定义重复统计的词汇
In [11]: terms = ['黄旭华', '核潜艇', '国立交通大学']
In [12]: #print(terms)
Out[12]: ['黄旭华', '核潜艇', '国立交通大学']
In [13]: terms
Out[13]: ['黄旭华', '核潜艇', '国立交通大学']
In [14]: # 学习一种新的数据结构，字典
In [15]: terms_dict = {}
In [16]: f_txt = open('科学家博物馆-黄旭华传记序言.txt', encoding = 'utf-8')
In [17]: data_txt = f_txt.read()
In [18]: f_txt.close()
```

②

在核潜艇领域，我国已形成一套完整的研究、设计、试验、制造、测试的核潜艇产业体系，而且装备了一支具有核潜艇研制能力的、成建制配备的、已近实现核潜艇建造和维修、运营、后勤保障、1400年，他毕业于国立交通大学船舶制造专业，先后从事过汽轮机船和军舰船舶的研究设计工作。1958年，黄旭华开始参与并领导我国第一代核潜艇的研究设计工作，先后任第一代核潜艇副总设计师、第二任总设计师，历任中国船舶工业总公司及中船重工集团第七一九船舶总设计师、副所长、所长、党委书记。黄旭华先后于1979年获中国科学院学位，1982年获国防科工委“一等奖”，1985年获核潜艇工业总公司劳动模范，1989年获授予“杰出总工程师”称号，他参与完成我国第一代核潜艇研制成功1989年获国家科技进步一等奖，领导核潜艇研制成功1996年获国家科技进步一等奖。

黄旭华出生于江苏太仓，尊理父老之堂，正直、勇敢、仁厚、坚毅的个性从小就给予了他良好的道德与文化的熏陶。在经历了韩屋小学、作城小学、李村中学、广福中学、桂林中学、歌舞部特大学先修班的学习历程之后，他凭借优异的成绩进入了当时著名的国立交通大学，系统学习造船专业理论与技术，以期实现“科学强国”的报国理想。同期在结友的环境下，历经风雨的洗礼成长成为一名坚定的共产党员。

新中国成立后，经过党校系统培训学习，黄旭华在政治思想上逐步成熟。经过苏联军事船舶的洗礼和磨砺，黄旭华在专业技术上也崭露头角。1958年，黄旭华因政治背景问题，专业技术精湛，成为开启“两工程”的最初专业技术人员之一，从此将自己的一生献给了祖国的核潜艇事业。在核潜艇的研制过程中，黄旭华秉持“自力更生、艰苦奋斗、大力协同、无私奉献”的核潜艇精神，践行“为党献身、为国防献身、为人民献身”的核潜艇理念，无私奉献。

```
In [20]: # 用count函数统计文本中的词汇

你没有发现下面的代码很神奇吗？data_txt.count一下，就可以统计词！实际上是字符串匹配的过程！

In [21]: for term in terms:
terms_dict[term]=data_txt.count(term)
In [22]: terms_dict
Out[22]: ['黄旭华': 59, '核潜艇': 32, '国立交通大学': 3]
In [23]: # 定义 画图 函数
In [24]: def make_chinese_plot_ready():
from matplotlib import rcsetup
rcsetup.rcParams['font.family'] = 'Heiti TC' # mac笔记本电脑直接替换字体
rcParams['font.sans-serif'] = ('FangSong') # 或者直接使用电脑有的字体 FangSong
rcParams['axes.unicode_minus'] = False
In [25]: # 定义 画图 函数
```

③

```
In [25]: # 定义 画图 函数
In [26]: def draw_dict(mydict, figsize=(8, 5)):
import pandas as pd
import matplotlib.pyplot as plt
make_chinese_plot_ready()
df = pd.DataFrame(list(mydict.items()), columns=['name', 'times'])
df.sort_index(inplace=True).sort_values(ascending=False).plot(kind='bar', figsize=figsize) # 做好排序
plt.tight_layout()
In [27]: # Apply inline
In [28]: %matplotlib inline
In [29]: draw_dict(terms_dict)
C:\will\site-packages\matplotlib\font_manager.py:1091: UserWarning: findfont: Font family ['Heiti TC'] not found. Falling back to DejaVu Sans
(prop.get_family(), self.defaultFamily(fontset))
```


第二讲 词频统计

2018-Wang 等 - Long live the scientists Tracking the scientific

研究背景

当下图书是人类知识与文明的重要载体，但在量化研究评估中未受足够重视。借助谷歌图书及 Ngram Viewer 等工具，可追溯长期文化演变，此前已有相关应用，本文旨在探究顶尖物理学家的科学声誉。

研究方法

以牛顿和爱因斯坦等物理学家为研究对象，整合谷歌图书（超 3600 万本）与谷歌学术（9100 多万篇文献）数据，运用关键词检索、共现分析等方法，结合不同语言语料，分析其声誉演变及相关成就。

研究结论

伟大物理学家的科学声誉跨越世纪，20 世纪中期后爱因斯坦在全球声誉超牛顿；存在群体内声誉偏好；二人声誉分别与经典物理成就、相对论等强相关，谷歌相关工具可作为替代计量工具。

第三讲 词云与可视化（词云）




这个词云图以“农业”“农民”为核心关键词（字体最大最突出），结合“种地”“土地”“资本”等词汇，聚焦农业与农民相关的主题，同时混搭了“鼓掌”“微笑”“玫瑰”“中国”等元素，呈现出一种多元且略带反差的内容组合。它的核心指向是农业、农民群体的相关话题，但加入“资本”可能关联农业领域的经济参与，而“鼓掌”“微笑”“玫瑰”这类偏感性 / 积极的词汇，则让主题多了些情感或象征层面的表达（比如对农民的认可、农业发展的美好意象），“中国”则点明了地域背景。

词云图（Word Cloud）是一种将文本数据中关键词的出现频率进行可视化呈现的图形工具，其核心特点是词频越高的词汇，在图中的字体越大、颜色越醒目，而词频较低的词汇则以较小的字体或较淡的颜色呈现。

在学术研究、数据分析、报告可视化等场景中，词云图能直观地提炼文本的核心主题与关键信息，帮助读者快速把握文本的重点内容。此外，词云图还可通过自定义字体、配色、形状等参数，适配不同的研究主题风格，增强可视化结果的美观度与针对性。



第三讲 词云与可视化(Echarts)




图一是 ECharts 的混合图表，用柱状图展示 Evaporation 和 Precipitation 数据，折线图展示 Temperature，清晰对比一周内的降水量、蒸发量与气温变化。

图二是 ECharts 的关系图，基于《悲惨世界》人物数据，用节点和连线呈现角色间的关联，不同颜色区分类别，直观展示人物关系网络。

图三是 ECharts 的回归分析图，用散点展示 1981-1998 年 GDP 数据，叠加指数回归曲线，呈现 GDP 的增长趋势并给出拟合公式。




第三讲 词云与可视化(Gephi)




第一张是 Gephi 生成的《悲惨世界》人物关系图，用不同颜色 / 大小的节点区分角色类别与关联度，直观呈现小说中人物的社交网络结构。

第二张是 Gephi 展示的 Java 项目依赖关系图，以节点和连线呈现 1538 个组件的 8032 条依赖关联，核心节点（红点）是依赖中心。



第三讲 词云与可视化(科学家文本的词云图绘制)



第四讲 情感分析（情感分析）

在线演示

中文分词

词性标注

命名实体识别

依存句法分析

成分句法分析

语义依存分析

语义角色标注

抽象意义表示

指代消解

语义文本相似度

文本风格转换

关键词短语提取

抽取式自动摘要

生成式自动摘要

文本纠错

文本分类

情感分析

HanLP / 演示 / 情感分析

情感分析

请输入一段中文文本：

“这是一部男人必看的电影。”人人都这么说。但单纯从性别区分，就会让这电影变狭隘。《肖申克的救赎》突破了男人电影的局限，通篇几乎充满令人难以置信的温馨基调，而电影里最伟大的主题是“希望”。当我们无奈地遇到了如同肖申克一般囚禁了心灵自由的那种困境，我们是无奈的老布鲁克，灰心的瑞德，还是智慧的安迪？运用智慧，信任希望，并且勇敢面对恐惧心理，去打败它？经典的电影之所以经典，因为他们都在做同一件事——让你从不同的角度来欣赏希望的美好。

215/1000

情感分析

情感极性



简介

第四讲 情感分析 (sentiment_analysis_1)

TextBlob（英文）、SnowNLP（中文）可快速做情感分析，输出极性 / 正面概率，但对短负面文本识别有偏差，难区分复杂情感类型。

①

```
jupyter sentiment_analysis_1_chuji Last Checkpoint: 12 分钟前 (autosaved)

File Edit View Insert Cell Kernel Widgets Help
Trusted Python 3

In [3]: text = "I am happy today. I feel sad today."
In [4]: from textblob import TextBlob
        blob = TextBlob(text)
In [5]: blob
Out[5]: TextBlob("I am happy today. I feel sad today.")
In [6]: # 默认不返回打印啥呢？
        # 实际上已经把文本分成了句子了，看一看
        blob.sentences
Out[6]: [Sentence("I am happy today."), Sentence("I feel sad today.")]
In [7]: blob.sentences[0].sentiment
Out[7]: Sentiment(polarity=0.8, subjectivity=1.0)
In [8]: # 上面的结果什么意思呢？
        # 情感极性0.8，主观性1.0，说明一下，情感极性的变化范围是[-1, 1]，-1代表完全负面，1代表完全正面，
        # 我通过的是取最大值，那么这个结果是好的
In [9]: blob.sentences[1].sentiment
Out[9]: Sentiment(polarity=-0.5, subjectivity=1.0)
In [10]: # 整段文本的情感呢？
        blob.sentiment
Out[10]: Sentiment(polarity=0.15000000000000002, subjectivity=1.0)
In [11]: # 你可能会觉得奇怪，怎么一句“高兴”，一句“遗憾”，会平均起来得到正向结果呢？
        # 事实上不同的词，在情感上是有影响的，我们应该可以联想到“高兴”更为正面的词，而且它出现的频率，确实比“无上一脚，抽一下”严重得多
```

②

```
jupyter sentiment_analysis_1_chuji Last Checkpoint: 12 分钟前 (autosaved)

File Edit View Insert Cell Kernel Widgets Help
Trusted Python 3

In [13]: text_cn = "我今天很快乐，我今天很愤怒。"
In [14]: # 注意在句首后面我们加了一个字母，它很重要，即为它提供Python，"这一段我们输入的文本编码格式是Unicode，则编码了嘛"，至于文本编码格式的细节，可
In [15]: from snowball import SnowNLP
In [16]: senti_cn = SnowNLP(text_cn)
In [17]: # 查看SnowNLP包的帮助文档
        for sentence in senti_cn.sentences:
            print(sentence)
        我今天很快乐
        我今天很愤怒
In [18]: senti_cn_1 = SnowNLP(senti_cn.sentences[0])
In [19]: # 一个细节上的问题，原文是a sentiment，中文是a sentiments，多了一个s
        # 另外，这句话上每段文本的情感值不同，比如最后那句，senti_cn.sentences[0].sentiments是会报错的
        senti_cn_1.sentiments
Out[19]: 0.911889500039116
In [20]: senti_cn_2 = SnowNLP(senti_cn.sentences[1])
In [21]: senti_cn_2.sentiments
Out[21]: 0.0776391377221482

这里你肯定发现了问题——“情感”这个词表达了如此强烈的负面情绪，为何得分依然靠近正？

这是因为SnowNLP和TextBlob的分析方法不同，SnowNLP的情感分析取值，表达的跟这句话代表正面情绪的概率，也就是说，对“我今天很快乐”一句，SnowNLP认为，它表达正面情绪的概率是很低低低。

这样解释就OK了
In [22]: senti_cn.sentiments
Out[22]: 0.7217619954203508
In [23]: # 每个句子，都只能看出来了
```


③

```
jupyter sentiment_analysis_1_chuji Last Checkpoint: 13 分钟前 (autosaved)

File Edit View Insert Cell Kernel Widgets Help
Trusted Python 3

In [24]: # 例如
        text_taobao_1 = "显示效果：挺好的 运行速度：目前来说蛮快 拍照效果：拍照效果挺好的 电池续航：一天一冲 总结：目前没啥毛病，用了一天的体验"
In [25]: taobao_1 = SnowNLP(text_taobao_1)
In [26]: taobao_1.sentiments
Out[26]: 0.99947261146011
In [27]: text_taobao_2 = "总结：这是我买过最不满意的一款手机！两千多元的手机这种，真的很不值！"
In [28]: taobao_2 = SnowNLP(text_taobao_2)
In [29]: for sentence in taobao_2.sentences:
            print(sentence)
        总结：这是我买过最不满意的手机
        两千多元的手机这种
        真的很不值
In [30]: taobao_2.sentiments
Out[30]: 0.889005139666256
In [31]: # 以上的结果看上去是有问题的，分析的不准确。
In [32]: text_taobao_3 = "显示效果：很差不行 运行速度：速度暂时没搞不了语音，得重新开机后才能发，才买半个月的手机就成这样，态度也很差！ 拍照效果：拍照
In [33]: taobao_3 = SnowNLP(text_taobao_3)
In [34]: taobao_3.sentiments
Out[34]: 5.70709422263434e-05
In [35]: # 这一句的结果还是可以，非常小的概率值了
In [36]: # 你的神句呢？
In [37]: # 神句？
In [ ]: #
```

①



第四讲 情感分析 (sentiment_analysis_3)

这个 Jupyter Notebook 代码是通过 DeepSeek API，从患者的健康描述文本中提取“身体部位、症状、对应情绪”这些细粒度信息，并以 JSON 格式返回结果。

①

```
import requests
import json

# DeepSeek API 端点
url = "https://api.deepseek.com/v1/chat/completions"

# 替换为您的 DeepSeek API 密钥
API_KEY = "sk-78d647279d40394135d9246255cfw" # 请替换成真实

# 请求头，包含 API 密钥和所需内容
headers = {
    "Authorization": f"Bearer {API_KEY}",
    "Content-Type": "application/json"
}

# 患者描述文本
text = """
我今年30岁，退休后感对生活失去了重心，开始出现失眠、头痛和精力无力的症状。
经常感到焦虑和心慌，心跳，睡眠质量很差，经常惊醒。
对光线和声音变得非常敏感，电话铃声会让我恐慌。
多次尝试就医，但结果显示没有器质性病变。
我逐渐意识到，不仅与人交流，甚至对自己关在屋里，拉窗帘，感觉生活毫无意义。
"""

# 构造提示词，要求模型提取细粒度的情感实体
prompt = """
请从以下患者描述中提取出具体的身体部位、症状以及对应的情绪状态。
并以 JSON 格式返回，格式如下：
{
  "身体": [{"部位": "...", "症状": "...", "情绪": "..."}], "value": ...
}
"""

# 请求体，包含模型参数和提示词
data = {
    "model": "deepseek-chat",
    "messages": [
        {
            "role": "user",
            "content": prompt
        }
    ],
    "temperature": 0.3
}

try:
    # 发送 POST 请求
    response = requests.post(url, headers=headers, data=json.dumps(data))
    # 检查响应状态码是否为 200
```

②


```
if response.status_code == 200:
    # 解析 JSON 响应
    result = response.json()
    # 提取模型生成的内容
    generated_text = result["choices"][0]["message"]["content"]
    print("提取细粒度情感抽取结果:")
    print(generated_text)
else:
    # 处理非 200 状态码
    print(f"请求失败，状态码: {response.status_code}")
    print(f"错误信息: {response.text}")

except requests.exceptions.RequestException as e:
    # 处理网络请求异常
    print(f"网络请求失败: {e}")
except json.JSONDecodeError as e:
    # 处理 JSON 解析异常
    print(f"JSON 解析失败: {e}")
except Exception as e:
    # 处理其他异常
    print(f"发生未知错误: {e}")

# 提取细粒度情感抽取结果:
{
  "身体": [
    {
      "部位": "全身/整体",
      "症状": "失眠、精力无力",
      "情绪": "焦虑、对生活失去重心、不愿出门、不愿与人交流、感觉生活毫无意义"
    },
    {
      "部位": "头部",
      "症状": "头痛",
      "情绪": "无"
    },
    {
      "部位": "皮肤",
      "症状": "经常敏感、触感和针扎疼痛",
      "情绪": "无"
    },
    {
      "部位": "心脏/胸部",
      "症状": "心慌、胸闷",
      "情绪": "无"
    },
    {
      "部位": "胃部",
      "症状": "无",
      "情绪": "无"
    }
  ]
}
```

第四讲 情感分析 (sentiment_analysis_4)

这个 Jupyter Notebook 代码是读取《背影》文本并分句，通过 DeepSeek API 对每句话提取一个核心情感词，同时给出 -1 到 1 的情感分值，最后输出每句的情感分析结果。



```
In [2]: import re

with open("背影.txt", "r", encoding="utf-8") as f:
    text = f.read()

# 按句号、感叹号、问号拆分句子 (保留标点)
sentences = re.split('([。！？])', text)
sentences = [s.strip() for s in sentences if s.strip()]
numbered_sentences = [(i + 1, s) for i, s in enumerate(sentences)]
#numbered_sentences = numbered_sentences[0:15] # 大模型抽取摘要，提取文本的前n条句子

for num, sent in numbered_sentences:
    print(f"{num}: {sent}")

In [3]: import requests
import time
import re

API_KEY = "sk-78d964727f0040394135d0240255fa" # 替换成自己的密钥
API_URL = "https://api.deepseek.com/v1/chat/completions"

headers = {
    "Content-Type": "application/json",
    "Authorization": f"Bearer {API_KEY}"
}

emotion_results = []

for num, sent in numbered_sentences:
    prompt = f"你是一个情感分析助手。请对下面这句话做如下分析：\n\n1. 提取或生成一个最能代表情感的词语（只能一个）；\n2. 对这句话的情感进行打分，范围是 -1（非常负面）到 1（非常正面），中性为 0。\n\n直接用如下格式输出：\n情感词: XXX\n情感值: X.X\n\n句子: {sent}"

    data = {
        "model": "deepseek-chat",
        "messages": [{"role": "user", "content": prompt}],
        "temperature": 0.3
    }

    response = requests.post(API_URL, headers=headers, json=data)
    result = response.json()
    message = result["choices"][0]["message"]["content"]

    # 提取情感词和分数
    match = re.search("情感词: (.*)\n情感值: (-?\d+\.\d+)", message)
    if match:
        word, score = match.groups()
        emotion_results.append((num, sent, word, score))

In [4]: for item in emotion_results:
    print(f"句子 {item[0]}: 情感词: {item[2]}, 情感值: {item[3]}")

句子1: 情感词: 怀念, 情感值: 0.3
句子2: 情感词: 悲伤, 情感值: -0.8
句子3: 情感词: 悲伤, 情感值: -0.7
句子4: 情感词: 悲伤, 情感值: -0.8
句子5: 情感词: 悲痛, 情感值: 0.3
句子6: 情感词: 沉重, 情感值: -0.8
句子7: 情感词: 悲伤, 情感值: -0.8
句子8: 情感词: 平静, 情感值: 0.0
句子9: 情感词: 平静, 情感值: 0.0
句子10: 情感词: 平静, 情感值: 0.1
句子11: 情感词: 关心, 情感值: 0.4
句子12: 情感词: 担忧, 情感值: -0.5
句子13: 情感词: 淡然, 情感值: 0.1
句子14: 情感词: 淡然, 情感值: 0.2
句子15: 情感词: 担忧, 情感值: -0.3
句子16: 情感词: 平静, 情感值: 0.0
句子17: 情感词: 中性, 情感值: 0.0
句子18: 情感词: 无奈, 情感值: -0.3
句子19: 情感词: 淡然, 情感值: 0.0
句子20: 情感词: 自嘲, 情感值: -0.3
句子21: 情感词: 遗憾, 情感值: 0.6
句子22: 情感词: 关心, 情感值: 0.8
句子23: 情感词: 遗憾, 情感值: 0.7
句子24: 情感词: 欣慰, 情感值: -0.5
句子25: 情感词: 欣慰, 情感值: -0.3
句子26: 情感词: 不舍, 情感值: -0.3
句子27: 情感词: 遗憾, 情感值: 0.4
句子28: 情感词: 关心, 情感值: 0.3
句子29: 情感词: 平静, 情感值: 0.1
句子30: 情感词: 欣慰, 情感值: -0.3
句子31: 情感词: 无奈, 情感值: -0.3
句子32: 情感词: 无奈, 情感值: -0.3
句子33: 情感词: 欣慰, 情感值: -0.3
句子34: 情感词: 担忧, 情感值: -0.3
句子35: 情感词: 努力, 情感值: 0.3
句子36: 情感词: 悲伤, 情感值: -0.8
句子37: 情感词: 欣慰, 情感值: -0.3
句子38: 情感词: 无奈, 情感值: -0.6
句子39: 情感词: 欣慰, 情感值: 0.3
句子40: 情感词: 遗憾, 情感值: 0.6
句子41: 情感词: 关心, 情感值: 0.3
句子42: 情感词: 遗憾, 情感值: 0.3
句子43: 情感词: 欣慰, 情感值: 0.6
句子44: 情感词: 幸福, 情感值: 0.3
```




南京工业大学
NANJING TECH
UNIVERSITY

02 关联数据分析



第六讲 知识图谱理念（实际产业案例分析）

在数字化转型深化与全球用户规模扩张的双重驱动下，企业级客服体系正面临着结构化需求提升与服务效率优化的核心挑战。作为全球领先的职业社交平台，领英（LinkedIn）截至2025年1月已拥有10.7亿用户，其客服场景覆盖会员账号管理、付费订阅、广告投放、招聘服务等多元业务，日均工单处理量达数万级。传统检索增强生成（RAG）技术在应对此类复杂场景时，因忽视工单结构化信息与工单间关联关系，导致检索精度不足、回答幻觉频发、问题解决周期过长等痛点。在此背景下，领英于2024年推出知识图谱与RAG深度融合（Graph-RAG）的技术方案，构建客服工单语义知识图谱生态，并于2025年实现全球客服体系规模化部署，成为B2B与B2C混合场景下知识图谱生态落地的标杆案例。本文将从生态构建逻辑、技术架构、落地成效、核心价值及挑战展望五个维度，对该最新进展展开深度分析。

第六讲 知识图谱理念（实际产业案例分析）

领英此次知识图谱生态构建的核心逻辑，是打破传统文本检索的信息割裂壁垒，通过图谱化重构客服领域知识体系，实现“结构化检索-精准推理-可追溯生成”的全链路优化。其生态构建并非孤立的技术迭代，而是深度联动领英既有的核心知识图谱资源，形成“业务图谱+工单图谱”的双轮驱动格局。领英原有核心知识图谱已沉淀会员、职位、公司、技能等海量实体及关联关系，此次新构建的客服工单语义图谱以历史JIRA工单为核心数据源，通过实体抽取、关系挖掘与结构解析，将分散的工单转化为“工单-问题-解决方案-关联实体”的树状结构化节点，并基于语义相似度、问题依赖性等维度实现工单间的关联链接，最终与核心业务图谱打通数据链路，形成覆盖“用户-业务-问题-解决方案”的全链条知识网络。这种生态构建思路既复用了既有知识资产，又针对性解决了客服场景的核心痛点，实现了技术价值与业务需求的精准匹配。

第六讲 知识图谱理念（实际产业案例分析）

此次知识图谱生态构建为领英带来了多重核心价值，既实现了客服体系的效率革新，更强化了企业知识资产的沉淀与复用价值。从直接业务价值来看，客服效率的提升直接降低了人力运营成本，据测算，解决时长缩短带来的人力成本节约每年超千万美元；同时，用户满意度较此前提升15%，付费会员续费率因服务体验优化提升8%，形成“服务优化-用户留存-商业增收”的正向循环。从知识资产价值来看，工单知识图谱的构建将分散的客服经验转化为结构化、可复用的知识资产，通过与核心业务图谱的联动，实现了“职位-技能-客服问题”的跨域推理，例如基于“用户职位为HR-技能为招聘管理-常见问题为招聘广告投放优化”的关联关系，可为特定用户群体提供预判式服务。从技术生态价值来看，领英的Graph-RAG方案验证了知识图谱在解决复杂场景文本检索痛点中的核心作用，其“结构化解析-图谱联动-可追溯生成”的技术路径，为其他企业级客服场景的知识图谱落地提供了标准化参考，推动了知识图谱与LLM融合技术在产业界的实践深化。

第六讲（2）知识图谱工具（检索、截图）

The screenshot displays the OpenKG website interface. The browser's address bar shows the URL: `data.openkg.cn/dataset/?organization=casia&tags=脑科学`. The website header includes the OpenKG logo and navigation links: 首页, 开放资源, 开放评测, 精选项目, 兴趣小组, 关于我们, and 致谢. A sidebar on the left contains filters for 机构 (Institution), 分类 (Category), 标签 (Tag), 格式 (Format), and 授权 (License). The main content area shows search results for '脑科学' (Neuroscience), displaying 4 datasets. The first result is '哺乳动物脑结构公共本体' (Mammalian Brain Structure Public Ontology), described as a project by the International Neuroinformatics Coordinating Committee (INICC) Neuroscience Body Project Group. The second result is 'Allen鼠脑结构本体中文版及扩展' (Allen Mouse Brain Structure Ontology Chinese Version and Extension), based on the Allen Human Brain Atlas Ontology. The third result is 'Allen人脑结构本体中文版及扩展' (Allen Human Brain Structure Ontology Chinese Version and Extension), also based on the Allen Human Brain Atlas Ontology. The fourth result is '脑科学关联知识图谱' (Neuroscience Associated Knowledge Graph), which integrates data and knowledge to build a neuroscience domain knowledge graph.

OpenKG.CN
中文开放知识图谱

登录 注册

首页 开放资源 开放评测 精选项目 兴趣小组 关于我们 致谢

数据集

机构

中国科学院自动化研究所 - 4

分类

医疗 - 4

标签

脑科学 - 4

健康 - 2

医学 - 1

认知科学 - 1

格式

OWL - 3

授权

Creative Commons... - 4

搜索数据集...

找到4个数据集

排序: 相关性

机构: 中国科学院自动化研究所 标签: 脑科学

哺乳动物脑结构公共本体

哺乳动物脑结构公共本体(CUMBO)是由国际神经信息学协调委员会神经科学本体项目组共同提出的项目。在参与此项目过程中,中科院自动化所类脑智能研究中心科研人员在公共术语的基础上对哺乳动物脑结构公共本体进行了如下贡献: (1) 脑组织间通过"sub-class of"和"part-of"关系进行组织。(2) 为每个术语分配了URI (3)...

OWL

Allen鼠脑结构本体中文版及扩展

此数据集在Allen鼠脑结构本体(Allen Human Brain Atlas Ontology)基础之上, 由中科院自动化所类脑智能研究中心进行了如下扩展: (1) 脑组织间通过"sub-class of"和"part-of"关系进行组织。(2) 为每个术语分配了URI (3) 为每个术语添加了到DBPedia的链接 (4) 为术语添加了中文翻译

OWL

Allen人脑结构本体中文版及扩展

此数据集在Allen人脑结构本体(Allen Human Brain Atlas Ontology)基础之上, 由中科院自动化所类脑智能研究中心进行了如下扩展: (1) 脑组织间通过"sub-class of"和"part-of"关系进行组织。(2) 为每个术语分配了URI (3) 为每个术语添加了到DBPedia的链接 (4) 为术语添加了中文翻译


OWL

脑科学关联知识图谱

通过数据与知识集成、文献自动分析与挖掘, 构建的脑科学领域关联知识图谱。图谱包含多尺度的脑结构(脑区、神经元、蛋白质、基

第六讲（2） 知识图谱工具（白板建模）

桃园结义·生死与共



关联关系解释


人物 - 事件关系：刘备、关羽、张飞三人因东汉末年的乱世背景相遇，在桃园共同发起结义事件，确立“异姓兄弟”的身份绑定。

人物 - 人物关系：三人以“兄友弟恭”为准则，刘备的“仁德”感召关羽、张飞，关羽的“忠义”和张飞的“豪爽”成为团队凝聚力的核心。

事件 - 背景关系：黄巾起义导致的天下大乱，是三人立下“匡扶汉室”志向的直接原因，也是桃园结义的历史必然性。

衍生关系：结义誓言成为三人一生的行为准则，衍生出“兄弟情谊超越生死”的精神内核，影响后续三顾茅庐、赤壁之战等事件。

第六讲（2） 知识图谱工具（echarts）



第六讲（2） 知识图谱工具 (Neo4j)

